

KCF Tracker による高速物体追跡*

内海 佑麻[†] (61602452)

2019/07/25

概要

現代的な物体追跡手法として、KCF Tracker (Kernelized Correlation Filter Tracker) を紹介し実装を行う。KCF Tracker は、データ行列に巡回性を持たせることにより、DCT による対角化が可能となり、処理にかかるメモリ容量および計算量を大幅に削減する。加えて、データ行列に対する正則化つき線形回帰問題を、カーネル法を用いて解くことで、カーネルトリックによる計算量削減を実現し、リアルタイムで高速な物体追跡を可能にする。なお、実装に使用したコードは、https://github.com/yumaloop/CV_report2019 で公開している。

目次

1	はじめに	2
1.1	Optical flow	2
2	理論	3
2.1	Ridge 回帰	3
2.2	巡回行列と DFT	4
2.3	巡回行列を使った Ridge 回帰	4
2.4	Kernel Ridge 回帰	5
2.5	巡回行列を使った Kernel Ridge 回帰	6
3	実装	6
3.1	詳細	6
3.2	結果	8
4	考察と結論	13

*慶應義塾大学 理工学研究科 2019 春学期 ”ComputerVision 特論” 最終レポート

[†]情報工学科 4 年, Email: uchiumi@ailab.ics.keio.ac.jp

1 はじめに

1.1 Optical flow

異なる時点の2画像間で、各画素値の移動量を表現したベクトルを Optical Flow という。Optical Flow により特徴点を検出することで、たとえば動画内の特定の物体を追跡することができる。まず、一般論として、勾配法 (Gradient-based method) による Optical Flow の求解手順を定式化する。勾配法では、Taylor 展開による近似を用いるため、「連続する2画像での対象物の移動が微小であること」を前提としている。

勾配法による Optical Flow の求解 画像 I における画素 (x, y) の時刻 t における画素値を $I(x, y, t)$ 、時間 Δt に対する画素値の移動量を $(\Delta x, \Delta y)$ とおく。移動前後で対象画素の画素値が不变であると仮定すると、

$$I(x, y, t) = I(x + \Delta x, y + \Delta y, \Delta t) \quad (1)$$

が成り立つ。さらに、画素値の変化が滑らかであると仮定すると、1次までの Taylor 展開により、以下の近似式を得る。

$$I(x, y, t) \approx I(x, y, t) + \frac{\partial I}{\partial x} \Delta x + \frac{\partial I}{\partial y} \Delta y + \frac{\partial I}{\partial t} \Delta t \quad (2)$$

両辺を Δt で割って、整理すると、

$$\frac{\partial I}{\partial x} \frac{\Delta x}{\Delta t} + \frac{\partial I}{\partial y} \frac{\Delta y}{\Delta t} + \frac{\partial I}{\partial t} = 0 \quad (3)$$

$\Delta t \rightarrow 0$ とすれば、

$$\frac{\partial I}{\partial x} \frac{\partial x}{\partial t} + \frac{\partial I}{\partial y} \frac{\partial y}{\partial t} + \frac{\partial I}{\partial t} = 0 \quad (4)$$

ここで、画素 (x, y) の Optical Flow: $(u, v) = \left(\frac{\partial x}{\partial t}, \frac{\partial y}{\partial t} \right)$ に着目する。 $I_x = \frac{\partial I}{\partial x}$, $I_y = \frac{\partial I}{\partial y}$, $I_t = \frac{\partial I}{\partial t}$, とおけば、 (u, v) がみたすべき方程式¹は、次式のようになる。

$$I_x u + I_y v + I_t = 0 \quad (5)$$

しかし、上式は2つの未知数 u, v に対して方程式は1つであり、解が定まらない²。[1] そのため、上式に加えて、いくつかの仮定(制約条件)を導入して Optical Flow: (u, v) を求める手法が提案されている。古典的で重要な手法として、Lucas-Kanade 法や Horn-Schunck 法がある。[2][3][4][5]

¹これを、OpticalFlow の拘束式と呼ぶ。

²これを、Aperture Problem(窓問題)という。

- Lucas-Kanade 法

「各画素の近傍では、移動方向が相関する」という仮定をおく。画像中の特定の点(領域)に絞って追跡を行うような用途に適しているため、sparse 型と呼ばれる。

- Horn-Schunck 法

「各画素は、変化率が最小となる方向へ移動する」という仮定をおく。画像中の画素全体の動きを解析するような用途に適しているため、dense 型と呼ばれる。

2 理論

Kernelized Correlation Filters[6]について解説する。

2.1 Ridge 回帰

SVMなどの洗練されたモデルに近い性能をもち、かつ単純な閉形式解³をもつ Ridge 回帰を用いる。 n 個の訓練データ $(\mathbf{x}_i, y_i)_{i=1 \dots n}$ に対する Ridge 回帰は、以下のように定式化される。

$$\min_{\mathbf{w}} \sum_{i=1}^n (f(\mathbf{x}_i) - y_i)^2 + \lambda \|\mathbf{w}\|^2, \quad f(\mathbf{x}_i) = \mathbf{w}^T \mathbf{x}_i \quad (6)$$

データ行列

$$X = \begin{bmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \mathbf{x}_3^T \\ \vdots \\ \mathbf{x}_N^T \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & x_{13} & \cdots & x_{1n} \\ x_{21} & x_{22} & x_{23} & \cdots & x_{2n} \\ x_{31} & x_{32} & x_{33} & \cdots & x_{3n} \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ x_{n1} & x_{n2} & x_{n3} & \cdots & x_{nn} \end{bmatrix} \quad (7)$$

を用いると、Ridge 回帰の閉形式解は、以下のようになる。

$$\mathbf{w} = (X^T X + \lambda I)^{-1} X^T \mathbf{y} \quad (8)$$

さらに、転置行列 X^T を、エルミート転置 $X^H := (X^*)^T$ によって拡張すると、

$$\mathbf{w} = (X^H X + \lambda I)^{-1} X^H \mathbf{y} \quad (9)$$

となる。⁴

³四則演算と初等関数の合成関数によって表せる解を、閉形式解 (closed-form solution) という。

⁴ A^* は、行列 A の複素共役を表す。

2.2 巡回行列と DFT

注目点の移動パスをベクトル $\mathbf{x} = (x_1, \dots, x_n)^T \in \mathbb{R}^n$ とおく。このとき, cyclic shift operator として, $n \times n$ 行列

$$P = \begin{bmatrix} 0 & 0 & 0 & \cdots & 1 \\ 1 & 0 & 0 & \cdots & 0 \\ 0 & 1 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 & 1 \end{bmatrix} \quad (10)$$

を定義すると, ベクトル \mathbf{x} の巡回置換は,

$$\{P^u \mathbf{x} \mid u = 0, \dots, n-1\} \quad (11)$$

と得られる。すなわち, あるベクトル \mathbf{x} から, n 個の仮想サンプルを作成することができる。そこで, ある信号 \mathbf{x} を, P を用いて拡張すると,

$$C(\mathbf{x}) = \begin{bmatrix} (P^0 \mathbf{x})^T \\ (P^1 \mathbf{x})^T \\ (P^2 \mathbf{x})^T \\ \vdots \\ (P^{n-1} \mathbf{x})^T \end{bmatrix} = \begin{bmatrix} x_1 & x_2 & x_3 & \cdots & x_n \\ x_n & x_1 & x_2 & \cdots & x_{n-1} \\ x_{n-1} & x_n & x_1 & \cdots & x_{n-2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_2 & x_3 & x_4 & \cdots & x_1 \end{bmatrix} \quad (12)$$

を得られる。ここで, $C(\mathbf{x})$ は巡回行列 (Circulant matrix) だから, これは DFT (Discrete Fourier Transform) によって対角化可能である。すなわち,

$$\forall \mathbf{z} \in \mathbb{R}^n, \quad F(\mathbf{z}) = \sqrt{n} F \mathbf{z} \quad (13)$$

をみたす, ある定まった DFT 行列 F と, \mathbf{x} の周波数成分

$$\hat{\mathbf{x}} = F(\mathbf{x}) = \sqrt{n} F \mathbf{x} \quad (14)$$

を用いると, $C(\mathbf{x})$ は次式のように固有値分解できる。

$$C(\mathbf{x}) = F \text{diag}(\hat{\mathbf{x}}) F^H \quad (15)$$

2.3 巡回行列を使った Ridge 回帰

$C(\mathbf{x})$ をデータ行列として, Ridge 回帰を行う, 中心化していない共分散行列は, DCT 行列 F を用いて次式のように表せる。

$$C(\mathbf{x})^H C(\mathbf{x}) = F \text{diag}(\hat{\mathbf{x}}^*) F^H F \text{diag}(\hat{\mathbf{x}}) F^H \quad (16)$$

さらに, 要素積 \odot を用いて

$$F^H F = (F^*)^T F = I \quad (17)$$

$$\text{diag}(\hat{\mathbf{x}}^*) \cdot \text{diag}(\hat{\mathbf{x}}) = \text{diag}(\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}}) \quad (18)$$

が成り立つから,

$$C(\mathbf{x})^H C(\mathbf{x}) = F \text{diag}(\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}}) F^H \quad (19)$$

となる. ここで, $\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}}$ は, 信号 \mathbf{x} の自己相関 (auto correlation) またはパワースペクトル (power spectrum) と呼ばれる量である. すなわち, P によって空間方向にシフトさせた信号どうしの共分散を表している. 以上から, データ行列として $C(\mathbf{x})$ を用いた Ridge 回帰の閉形式解は, 次のようになる.

$$\hat{\mathbf{w}} = (C(\mathbf{x})^H C(\mathbf{x}) + \lambda I)^{-1} C(\mathbf{x})^H \hat{\mathbf{y}} \quad (20)$$

$$= \text{diag} \left(\frac{\hat{\mathbf{x}}^*}{\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}} + \lambda} \right) \hat{\mathbf{y}} \quad (21)$$

$$= \frac{\hat{\mathbf{x}}^* \odot \hat{\mathbf{y}}}{\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}} + \lambda} \quad (22)$$

$$(23)$$

よって, 逆 DFT^{-1} を用いて, w が求められる.

$$\mathbf{w} = F^{-1}(\hat{\mathbf{w}}) \quad (24)$$

2.4 Kernel Ridge 回帰

任意の正定値関数 $k(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$ に対して,

$$\mathbf{w} = \sum_{i=1}^n \alpha_i \phi(\mathbf{x}_i) \quad (25)$$

とおけば, グラム行列

$$K = \begin{bmatrix} k(\mathbf{x}_1, \mathbf{x}_1) & k(\mathbf{x}_1, \mathbf{x}_2) & k(\mathbf{x}_1, \mathbf{x}_3) & \cdots & k(\mathbf{x}_1, \mathbf{x}_n) \\ k(\mathbf{x}_2, \mathbf{x}_1) & k(\mathbf{x}_2, \mathbf{x}_2) & k(\mathbf{x}_2, \mathbf{x}_3) & \cdots & k(\mathbf{x}_2, \mathbf{x}_n) \\ k(\mathbf{x}_3, \mathbf{x}_1) & k(\mathbf{x}_3, \mathbf{x}_2) & k(\mathbf{x}_3, \mathbf{x}_3) & \cdots & k(\mathbf{x}_3, \mathbf{x}_n) \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ k(\mathbf{x}_n, \mathbf{x}_1) & k(\mathbf{x}_n, \mathbf{x}_2) & k(\mathbf{x}_n, \mathbf{x}_3) & \cdots & k(\mathbf{x}_n, \mathbf{x}_n) \end{bmatrix} \quad (26)$$

を用いて, Representer 定理より,

$$f(\mathbf{x}_i) = \mathbf{w}^T \mathbf{x}_i = \sum_{j=1}^n \alpha_j k(\mathbf{x}_i, \mathbf{x}_j) \quad (27)$$

$$\|\mathbf{w}\|^2 = \alpha^T K \alpha \quad (28)$$

が成り立つ. すなわち, n 個の訓練データ $(\mathbf{x}_i, y_i)_{i=1 \dots n}$ に対する Kernel Ridge 回帰は, 以下のように定式化される.

$$\min_{\alpha} \sum_{i=1}^n (f(\mathbf{x}_i) - y_i)^2 + \lambda \alpha^T K \alpha, \quad f(\mathbf{x}_i) = \sum_{j=1}^n \alpha_j k(\mathbf{x}_i, \mathbf{x}_j) \quad (29)$$

Kernel Ridge 回帰の閉形式解は, 以下のようになる.

$$\alpha = (K + \lambda I)^{-1} \mathbf{y} \quad (30)$$

2.5 巡回行列を使った Kernel Ridge 回帰

Ridge 回帰と同様に、ベクトル \mathbf{x} とその巡回シフトに対するカーネルは、 P と $k(\cdot, \cdot)$ を用いて

$$\{k(\mathbf{x}, P^u \mathbf{x}) \mid u = 0, \dots, n-1\} \quad (31)$$

となる。よって、ベクトル $\mathbf{k}^{\mathbf{xx}}$ を、

$$\mathbf{k}_i^{\mathbf{xx}} = k(\mathbf{x}, P^{i-1} \mathbf{x}) \quad (i = 1, \dots, n) \quad (32)$$

と定義し、これを用いた巡回行列

$$C(\mathbf{k}^{\mathbf{xx}}) = \begin{bmatrix} (P^0 \mathbf{k}^{\mathbf{xx}})^T \\ (P^1 \mathbf{k}^{\mathbf{xx}})^T \\ \vdots \\ (P^{n-1} \mathbf{k}^{\mathbf{xx}})^T \end{bmatrix} = \begin{bmatrix} k(\mathbf{x}, P^0 \mathbf{x}) & k(\mathbf{x}, P^1 \mathbf{x}) & \cdots & k(\mathbf{x}, P^{n-1} \mathbf{x}) \\ k(\mathbf{x}, P^{n-1} \mathbf{x}) & k(\mathbf{x}, P^0 \mathbf{x}) & \cdots & k(\mathbf{x}, P^{n-2} \mathbf{x}) \\ \vdots & \vdots & \ddots & \vdots \\ k(\mathbf{x}, P^1 \mathbf{x}) & k(\mathbf{x}, P^2 \mathbf{x}) & \cdots & k(\mathbf{x}, P^0 \mathbf{x}) \end{bmatrix} \quad (33)$$

を得られる。さらに、中心化していない共分散行列は、DCT 行列 F を用いて次式のように表せる。

$$C(\mathbf{k}^{\mathbf{xx}})^H C(\mathbf{k}^{\mathbf{xx}}) = F \text{diag} \left(\hat{\mathbf{k}}^* \odot \hat{\mathbf{k}}^{\mathbf{xx}} \right) F^H \quad (34)$$

以上から、データ行列として $C(\mathbf{k}^{\mathbf{xx}})$ を用いた Kernel Ridge 回帰の閉形式解は、次のようになる。

$$\hat{\alpha} = (C(\mathbf{k}^{\mathbf{xx}}) + \lambda I)^{-1} \mathbf{y} \quad (35)$$

$$= \frac{\hat{\mathbf{y}}}{\hat{\mathbf{k}}^{\mathbf{xx}} + \lambda} \quad (36)$$

よって、逆 DFT F^{-1} を用いて、 w が求められる。

$$\alpha = F^{-1}(\hat{\alpha}) \quad (37)$$

3 実装

3.1 詳細

カーネル関数 RBF kernel(Gaussian Kernel) を用いる。

$$\mathbf{k}^{\mathbf{xx}'} = \exp \left\{ -\frac{1}{\sigma^2} \left(\|\mathbf{x}\|^2 + \|\mathbf{x}'\|^2 - 2F^{-1}(\hat{\mathbf{x}}^* \odot \hat{\mathbf{x}}') \right) \right\} \quad (38)$$

実行環境 以下の環境でプログラムを実装した。主要なスクリプトの記述にはPythonを採用した。使用したコードは、https://github.com/yumaloop/CV_report2019で公開した。

- OS: macOS Mojave 10.14.4
- App: QuickTime Player 10.5 (935.3), iMovie (10.1.12)
- Lang: Python 3.7.4
- Lib: Numpy 1.16.1, OpenCV-python 4.1.0

なお、今回は、KCF Tracker アルゴリズムのみを実装したため、動画の入出力やユーザインターフェースは、OpenCV の定義済み関数を利用した。具体的に、KCF Tracker のオブジェクトをインポートできる OpenCV の cv2.TrackerKCF_create() を使って、Object Trackingを行うコードは次のようになる。このうち、コード中のオブジェクト tracker と関連する処理を実装した。

```
import sys
import cv2

# Set up tracker as KCF.
tracker = cv2.TrackerKCF_create()

# cap: captured images from the video
input_file = "*****.mp4"
cap = cv2.VideoCapture(input_file)
cap_width = int(cap.get(cv2.CAP_PROP_FRAME_WIDTH))
cap_height = int(cap.get(cv2.CAP_PROP_FRAME_HEIGHT))
cap_size = (cap_width, cap_height)

# out: result video (m4v)
# see also https://gist.github.com/takuma7/44f9ecb028ff00e2132e
output_file = "*****.m4v"
fourcc = cv2.VideoWriter_fourcc('m', 'p', '4', 'v')
out = cv2.VideoWriter(output_file, fourcc, 20.0, cap_size)

# Exit if video not opened.
if not cap.isOpened():
    print("Cannot open the video file.")
    sys.exit()

# Read first frame.
ret, frame = cap.read()
if not ret:
    print('Cannot read the video file.')
    sys.exit()

# Initialize bounding box
bbox = (287, 23, 86, 320)
# Uncomment the line below to select a different bounding box
# bbox = cv2.selectROI(frame, False)
```

```

# Initialize tracker
ret = tracker.init(frame, bbox)

while True:
    # Read a new frame
    ret, frame = cap.read()
    if not ret: break

    # =====
    ''' Update tracker (Tracking process in OpenCV) '''
    ret, bbox = tracker.update(frame)
    # =====

    # Draw bounding box
    if ret:
        # Tracking succeeded
        p1 = (int(bbox[0]), int(bbox[1]))
        p2 = (int(bbox[0] + bbox[2]), int(bbox[1] + bbox[3]))
        cv2.rectangle(frame, p1, p2, (255,0,0), 2, 1)
    else :
        # Tracking failed
        cv2.putText(frame, "Tracking failure detected",
                    (100, 80), cv2.FONT_HERSHEY_SIMPLEX, 0.75, (0,0,255) ,2)

    # Display result
    cv2.imshow("Tracking", frame)

    # Save result as mp4 file
    out.write(frame)

    # Exit if ESC pressed
    k = cv2.waitKey(1) & 0xff
    if k == 27:
        break

```

使用した動画ファイル 4つのmp4形式のファイルを入力ファイルとして、動画中の物体を矩形で囲み追跡した。

- chaplin.mp4
- car1.mp4
- car2.mp4
- bus1.mp4

3.2 結果

それぞれの入力ファイルに対して、OpenCVに定義されているKCF Trackerと、実装したKCF Trackerで物体追跡を行い。出力結果を比較する。また、出力された動画ファイルを再生し、0.5 secごとにフレームを画像として保存したものを掲載する。

chaplin.mp4 動画(グレースケール)上の人物の追跡を行なった。OpenCVのKCF Tracker(図1参照)と実装したKCF Tracker(図2参照)で大きな差はなかったが、実装したものの方がフレーム毎のbounding boxの変化が大きい。これは、画像(動画)に応じて、KCFに用いるpadding sizeやRBF kernelの σ の大きさなどで調節可能である。

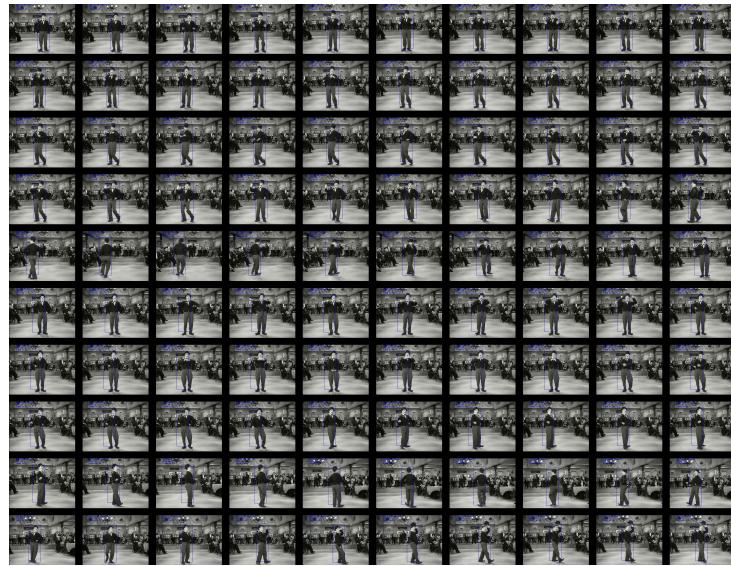


図 1: chaplin.mp4 に対して、OpenCV KCF Tracker で物体追跡を行なった結果

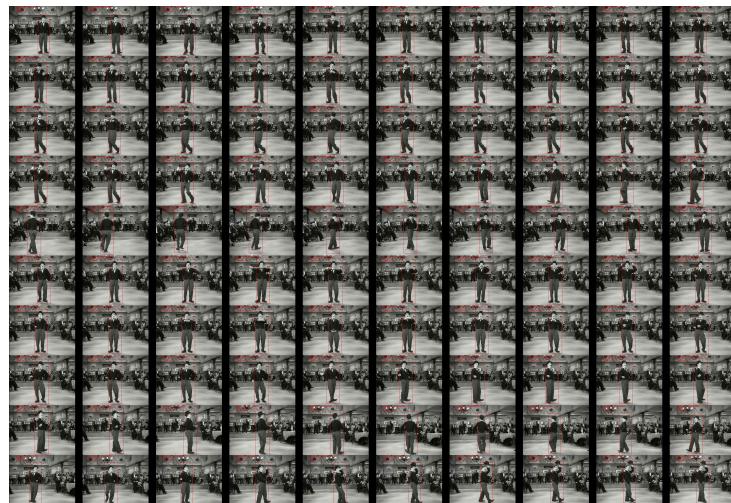


図 2: chaplin.mp4 に対して、実装した KCF Tracker で物体追跡を行なった結果

car1.mp4 動画 (RGB) 上の車の追跡を行なった. OpenCV の KCF Tracker(図 3 参照)よりも, 実装した KCF Tracker(図 4 参照)の方が精度良く追跡できているように見える. 画像中の物体の depth をうまく捉える必要があるが, 実装したものでは, フレーム毎に bounding box が小さくなり, 車の輪郭を捉えることができた.

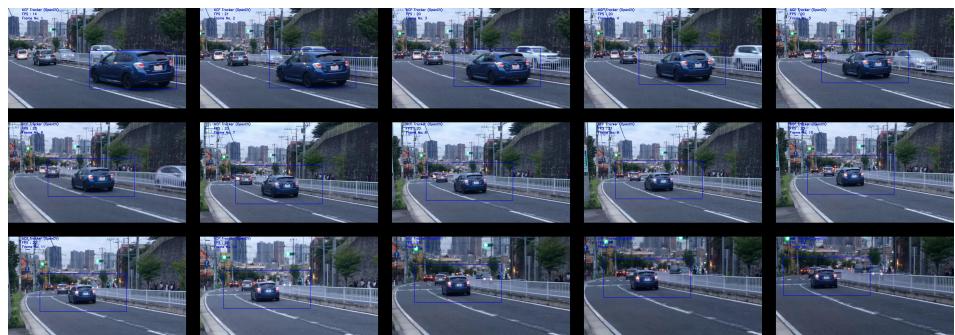


図 3: car1.mp4 に対して, OpenCV KCF Tracker で物体追跡を行なった結果

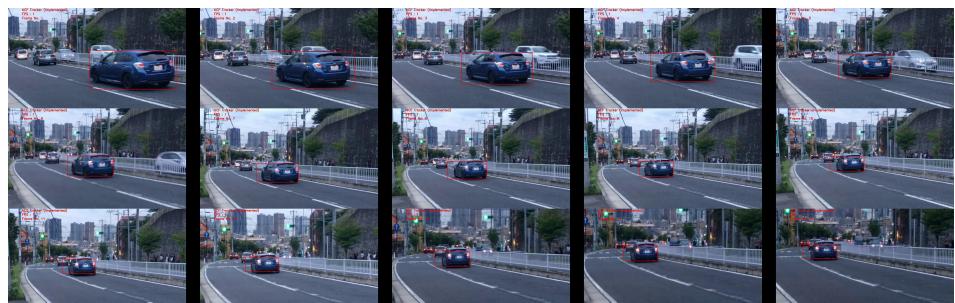


図 4: car1.mp4 に対して, 実装した KCF Tracker で物体追跡を行なった結果

car2.mp4 動画 (RGB) 上の車の追跡を行なった。OpenCV の KCF Tracker(図 5 参照)と、実装した KCF Tracker(図 6 参照)で大きな差異はみられなかった。

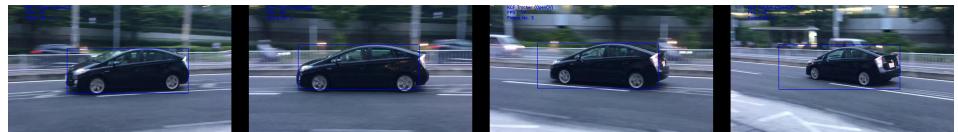


図 5: car2.mp4 に対して、OpenCV KCF Tracker で物体追跡を行なった結果



図 6: car2.mp4 に対して、実装した KCF Tracker で物体追跡を行なった結果

bus1.mp4 動画 (RGB) 上のバスの追跡を行なった。実装した KCF Tracker(図 8 参照)よりも、OpenCV の KCF Tracker(図 7 参照)の方が精度良く追跡できているように見える。

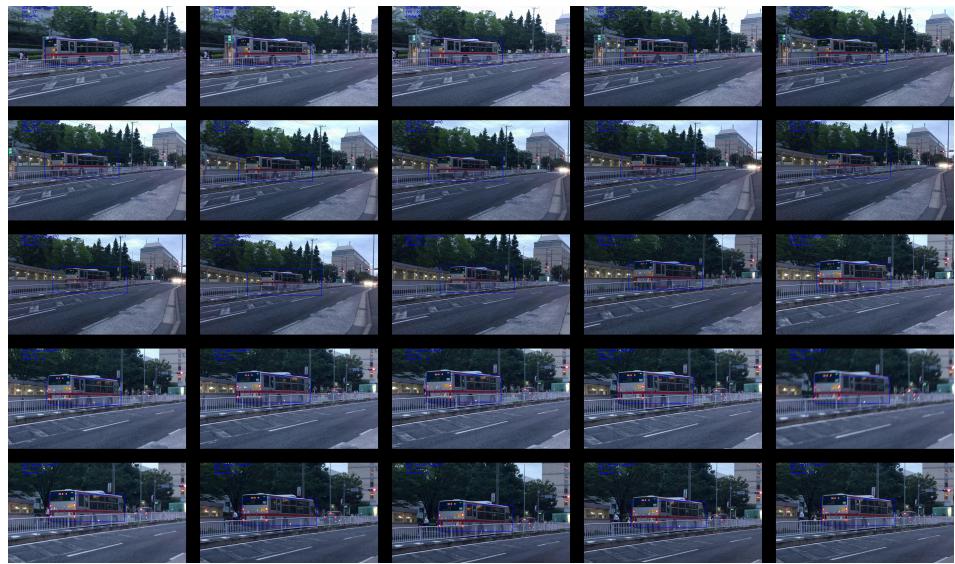


図 7: bus1.mp4 に対して、OpenCV KCF Tracker で物体追跡を行なった結果



図 8: bus1.mp4 に対して、実装した KCF Tracker で物体追跡を行なった結果

4 考察と結論

KCF Trackerについて 現代的な物体追跡手法を比較すると、図9のようになる。[7] 近年では、Deep Neural Networkと用いた大規模なモデルと、GPUによる演算処理が隆盛を極めており、精度(Precision, IOU(AUC))においてはこれらが優位とされている。一方で、リアルタイム性やFPSを考慮すると、KCF Trackerも十分有用であるとも言える。

Table 1: Summary of experiments on OTB-100.

	Algorithm	Prec.(20px)	IOU(AUC)	FPS	GPU
Non real-time	ADNet	88.0%	0.646	2.9	O
	ADNet-fast	85.1%	0.635	15.0	O
Non real-time	MDNet [24]	90.9%	0.678	< 1	O
	C-COT [9]	90.3%	0.673	< 1	O
	DeepSRDCF [8]	85.1%	0.635	< 1	O
	HDT [25]	84.8%	0.564	5.8	O
	MUSTer [15]	76.7%	0.528	3.9	X
Real-time	MEEM [42]	77.1%	0.528	19.5	X
	SCT [5]	76.8%	0.533	40.0	X
	KCF [13]	69.7%	0.479	223	X
	DSST [7]	69.3%	0.520	25.4	X
	GOTURN [12]	56.5%	0.425	125	O

図9: 近年の Object Tracking 手法の比較 [7]

OpenCV と実装した処理系との差異 今回は、KCF Tracker の実装において、ほぼすべての積和演算を Python(Numpy) で記述したため、C++で記述されている OpenCV の KCF Tracker と比較して、FPSではx10 x20程度の差が発生した。物体追跡は応用上、精度と共にリアルタイム性が求められるため、アルゴリズムを固定していても、ソフトウェアやアプリケーションレベルでの高速化が求められるということを認識した。

まとめ OpenCV の Object Tracking ツールとして提供されている手法の1つとして、KCF Tracker[6]の実装を行い、実際に撮影した動画(RGB)で物体追跡を行なった。KCF Trackerは、離散フーリエ変換による空間表現から周波数表現への変換、巡回行列のもつ線型独立性の応用、Ridge回帰に対するカーネル法の導入、など提案手法中に様々な要素技術が登場するため、実装に取り組む上で大変示唆的な経験を得られた。

参考文献

- [1] Richard Szeliski. *Computer Vision: Algorithms and Applications*. Springer-Verlag, Berlin, Heidelberg, 1st edition, 2010.
- [2] Berthold K.P. Horn and Brian G. Schunck. Determining optical flow. Technical report, Cambridge, MA, USA, 1980.
- [3] Bruce D. Lucas and Takeo Kanade. An iterative image registration technique with an application to stereo vision. In *Proceedings of the 7th International Joint Conference on Artificial Intelligence - Volume 2*, IJCAI'81, pp. 674–679, San Francisco, CA, USA, 1981. Morgan Kaufmann Publishers Inc.
- [4] Chris Harris and Mike Stephens. A combined corner and edge detector. In *In Proc. of Fourth Alvey Vision Conference*, pp. 147–151, 1988.
- [5] Carlo Tomasi and Takeo Kanade. Detection and tracking of point features. Technical report, International Journal of Computer Vision, 1991.
- [6] João F. Henriques, Rui Caseiro, Pedro Martins, and Jorge Batista. High-speed tracking with kernelized correlation filters. *CoRR*, Vol. abs/1404.7584, , 2014.
- [7] Sangdoo Yun, Jongwon Choi, Youngjoon Yoo, Kimin Yun, and Jin Young Choi. Action-decision networks for visual tracking with deep reinforcement learning. In *The IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017.